

Modelo de controlador preditivo para rastreamento de trajetória de robôs omnidirecionais com tratamento de restrições

Francisco Arthur Bonfim Azevedo *

* Instituto Tecnológico de Aeronáutica,
Praça Marechal Eduardo Gomes, 50, Vila das Acácias, 12228-900,
São José dos Campos, SP, Brasil,
(e-mail: arthurazevedo41@gmail.com).

Abstract: This work study and develops a MPC to a omnidirecional robot, turned to the trajectory tracking with actuation constraints. The dynamic of the sistem is nonlinear, but linearization around a reference results in a linear time-varying system. Finally, simulations are show to validate and analyze the proposed method.

Resumo: O presente trabalho estuda e desenvolve um controlador do tipo preditivo para um robô omnidirecional, voltado para o rastreo de trajetórias com respeito a restrições. A dinâmica do sistema é não-linear, mas a linearização em torno de uma referência resulta em um sistema linear variante no tempo. Por fim, são mostradas simulações para validar e analisar o método proposto.

Keywords: Model Preditive Control; Robotic; Robot Control; Omnidirecional; Mobile Robot; Constraints.

Palavras-chaves: Controle Preditivo; Robótica; Controle de Robôs; Omnidirecional; Robótica móvel; Restrições.

1. INTRODUÇÃO

Robô omnidirecional é uma classe da robótica móvel com robôs que podem se mover facilmente para qualquer direção no plano. Para ser capaz de realizar esse movimento, pode-se utilizar de diversas técnicas, variando geometria, direção, disposição e velocidade das rodas. Um exemplo de robô omnidirecional, o qual é tratado no presente trabalho, é o Small Size.

A *Small Size League* (SSL) é uma competição de futebol de robôs omnidirecionais com partidas de dois times de 6 robôs no caso da divisão B ou 8 robôs no caso da divisão A (RoboCup, 2019). As regras estabelecem que os robôs caibam em um cilindro de 180 mm de diâmetro e 150 mm de altura. Em geral, os robôs possuem 4 rodas, com vários pequenos roletes nelas, com o número variando de equipe para equipe, que são responsáveis pelo movimento omnidirecional do robô. O sistema de visão é composto por câmeras posicionadas no teto do campo e algoritmos de visão capazes de identificar cada robô graças a um padrão de marcações coloridas posicionado na parte superior de cada um, medindo sua posição e sua orientação. A maior parte do processamento, como algoritmos de estratégia e de cálculo de trajetórias, ocorrem em um computador central que se comunica com os robôs por rádio.

Uma habilidade importante de um robô Small Size é a de se movimentar rapidamente pelo campo enquanto desvia de outros jogadores, tanto para alcançar a bola, quando para

armar jogadas e preparar para passes. O presente trabalho documenta um controlador para rastreamento de trajetórias para a equipe Small Size da ITAndroids. ITAndroids é um grupo do Instituto Tecnológico de Aeronáutica (ITA) que participa de competições de robótica. O grupo também desenvolve outros robôs, em categorias simuladas como é o caso do *Soccer 2D*, *Soccer 3D* e categorias físicas como é o caso da *Humanoid Kid-Size* e *VSS*, além de competir em competições nacionais como a *LARC (Latin American Robotics Competition)* e internacionais como a *RoboCup*. O robô Small Size da equipe e sua roda pode ser visto na Figura 1.




Figura 1. Robô Small Size da equipe ITAndroids.

É comum na robótica móvel dividir o movimento do robô em duas camadas: planejamento e controle (Maximo, 2012). Primeiramente, o robô planeja qual seria a melhor trajetória que ele deveria seguir para atingir seu objetivo,

desviando de obstáculos, e, em seguida, o controle age obtendo os comandos que o robô deve obedecer para seguir fisicamente possível seguir a dada trajetória. O problema do planejamento é geralmente resolvido através do emprego de algoritmos como A* ou *Rapid Exploring Random Tree* (RRT) (Siegwart et al., 2011). Já o controle é resolvido através de técnicas da teoria de controle (Maximo, 2012; Camacho and Bordons, 2007; Klančar and Škrjanc, 2007). No presente trabalho, a atenção será voltada para o controle do robô sobre uma trajetória pré-definida, por tanto, será assumido que a trajetória já foi planejada.

Uma dessas técnicas de controle é o Controle Preditivo, ou MPC (*Model Predictive Control*), a qual será aqui tratada e aplicada. Controle preditivo é uma técnica de controle ótimo que se baseia em levar em conta o comportamento futuro do sistema para corrigir o sistema no presente (Maximo, 2012). Ele age em tempo discreto e requer resolver problemas de otimização em cada *time step* considerando um número fixo de passos futuros, conhecidos como horizonte de controle. Uma das grandes vantagens do MPC é o fato de ele lidar muito bem com restrições, as quais também são incluídas em um problema de otimização que deve ser resolvido em cada *time step*, obtendo assim não apenas um comando que obedece as restrições, mas um valor ótimo de comando para o dado caso. A solução desses problemas de otimização com restrições requerem soluções numéricas através de algoritmos iterativos, o que faz com que o MPC seja naturalmente um controlador pesado computacionalmente.

No caso do robô Small Size, existem restrições quanto a velocidade de rotação das rodas e tensão máxima que o motor é capaz de suportar. Utilizando controladores como o PID esses problemas de restrição são resolvidos através de saturação do comando no robô, o que não é tão efetivo quanto a abordagem do MPC, que consegue calcular o controle ótimo até nesses casos, e, portanto, por esse ponto de vista o controle preditivo se sobressai em relação ao PID. Por isso, decidiu-se utilizar o MPC para um controlador para seguir trajetória no Small Size da ITAndroids.

2. MODELO DO ROBÔ

O modelo do robô é feito com base no ambiente da competição da SSL e nos robôs Small Size utilizados pela ITAndroids (Maximo, 2018). Seja $q = [x, y, \phi]^T$ o vetor de estados do robô sendo definido em relação a um sistema global de coordenadas, que no caso da SSL fica no centro do campo. Os pontos x e y são tomados em relação ao centro do robô e o ângulo ϕ toma-se como referência a frente do robô. Além disso, considera-se que cada roda tem sua velocidade controlada, o que no nosso caso é feito através de um controlador PID com realimentação feita pela leitura do encoder.

2.1 Modelo cinemático

Agora, toma-se um sistema de coordenadas x_r, y_r solidário ao robô com origem em seu centro e com o eixo x_r alinhado com a frente do robô. Denota-se por v, v_n e ω as velocidades frontal, lateral e angular, respectivamente. Os sistemas de referência podem ser vistos na Figura 2.




Figura 2. Convenções relativas a sistemas de coordenadas cartesianos.

A numeração de cada roda é feita como na Figura 3a seguindo o sentido anti-horário, a partir do eixo x_r . A convenção de velocidade angular da roda é feita de modo a manter a consistência com a sua velocidade linear, de forma que, para a i -ésima roda vale $v_i = \omega_i r_i$, sendo v_i , ω_i e r_i respectivamente a velocidade linear, a velocidade angular e o raio da i -ésima roda, respectivamente.

Quanto a roda, considera-se uma roda omnidirecional genérica a uma distância l do ponto de referência e posicionada conforme os ângulos α e β , conforme a Figura 3b. Por fim, a condição de não deslizamento para cada roda está expressa na Equação (1).




Figura 3. Modelagem das rodas do robô.

$$v_w = \omega_w r = -\sin(\alpha + \beta)v + \cos(\alpha + \beta)v_n + l\cos(\beta)\omega \quad (1)$$

Sendo: v_w e ω_w a velocidade linear e angular da roda, respectivamente. Para expressar simultaneamente as 4 rodas, coloca-se na forma matricial conforme a Equação 2. A matriz M mapeia a velocidade do robô nas velocidades das rodas.

$$\underbrace{\begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{bmatrix}}_{v_w} = \underbrace{\begin{bmatrix} -\sin(\alpha_1 + \beta_1) & \cos(\alpha_1 + \beta_1) & l_1 \cos(\beta_1) \\ -\sin(\alpha_2 + \beta_2) & \cos(\alpha_2 + \beta_2) & l_1 \cos(\beta_2) \\ -\sin(\alpha_3 + \beta_3) & \cos(\alpha_3 + \beta_3) & l_1 \cos(\beta_3) \\ -\sin(\alpha_4 + \beta_4) & \cos(\alpha_4 + \beta_4) & l_1 \cos(\beta_4) \end{bmatrix}}_M \underbrace{\begin{bmatrix} v \\ v_n \\ \omega \end{bmatrix}}_{v_r} \quad (2)$$

Como a matriz M não é quadrada, para isolar o vetor v_r , utiliza-se a pseudoinversa M^+ da matriz M , conforme representado na Equação (3).

$$v_r = M^+ v_w = (M^T M)^{-1} M^T v_w \quad (3)$$

2.2 Modelo dinâmico

Para o modelo dinâmico do robô será utilizada a formulação de mecânica Lagrangeana. As coordenadas generalizadas escolhidas são os ângulos de rotação das rodas $q = [\theta_1 \theta_2 \theta_3 \theta_4]^T$. Da formulação da mecânica Lagrangeana, tem-se a Equação (4).

$$\frac{d}{dt} \left(\frac{\partial L}{\partial \dot{q}} \right) - \frac{\partial L}{\partial q} = \tau \quad (4)$$

Sendo L a lagrangeana do sistema e τ o vetor de forças generalizadas, que no caso trata-se do torque aplicado pelas rodas. A lagrangeana é dada pela Equação (5).

$$L = T - V \quad (5)$$

Em que T e V são, respectivamente, as energias cinética e potencial do sistema. No caso tratado, a energia potencial é devida a gravidade, mas como o robô se move no plano, tem-se $V = 0$. Já a energia cinética será dada pela Equação (6).

$$T = \frac{1}{2} m v_{cm}^T v_{cm} + \frac{1}{2} I_{cm} \omega^2 \quad (6)$$

Sendo m a massa do robô, I_{cm} o momento de inércia em relação ao centro de massa (CM) e v_{cm} o vetor velocidade linear do centro de massa. Preferiu-se não adicionar as energias cinéticas de rotação do motor e da roda pois pode-se adicionar posteriormente os efeitos dos torques para acelerar o motor e a roda (Maximo, 2018). Porém, incluir ou não essas energias altera a interpretação de τ . Se essas energias não são incluídas, τ representa torques aplicados pela roda no chão, depois de já ter sido descontados os torques para acelerar o motor e a roda.

Escrevendo v_{cm} projetado no sistema de referência do robô x_r, y_r , sendo um deslocamento de $r_{cm} = [x_{cm} \ y_{cm} \ z_{cm}]^T$ do CM em relação ao ponto de referência, tem-se a Equação (7).

$$v_{cm} = \begin{bmatrix} v \\ v_n \\ 0 \end{bmatrix} + \omega \hat{k} \times \begin{bmatrix} x_{cm} \\ y_{cm} \\ z_{cm} \end{bmatrix} \Rightarrow v_{cm} = \begin{bmatrix} v - \omega y_{cm} \\ v_n + \omega x_{cm} \\ 0 \end{bmatrix} \quad (7)$$

Por fim, falta colocar colocar v, v_n e ω nas coordenadas generalizadas q . Para isso, basta se utilizar da Equação (3).

Substituindo as Equações (3) e (7) em (6) obtêm-se a expressão da lagrangeana, que por fim deve ser substituída na Equação (4), obtendo-se as equações dinâmicas do robô. A solução será da forma da Equação (8).

$$H_r \underbrace{\begin{bmatrix} \dot{\omega}_1 \\ \dot{\omega}_2 \\ \dot{\omega}_3 \\ \dot{\omega}_4 \end{bmatrix}}_{\dot{v}_w} = \underbrace{\begin{bmatrix} \tau_1 \\ \tau_2 \\ \tau_3 \\ \tau_4 \end{bmatrix}}_{\tau} \quad (8)$$

Com H_r sendo a matriz que descreve a dinâmica do robô.

Agora, desconta-se os torques necessários para acelerar o motor e a roda. O torque gerado no i -ésimo motor é usado para acelerar o próprio motor, a respectiva roda e fornecer τ , logo, utilizando-se as equações de modelamento de motor elétrico, tem-se as Equações (9), (10) e (11).

$$\tau_g = K j_i - J_m n \dot{\omega}_i - B_m N \dot{\omega}_i \quad (9)$$

$$\tau_e = N \eta \tau_g \quad (10)$$

$$\tau_e = J_w \dot{\omega}_i + B_m \dot{\omega}_i + \tau_i \quad (11)$$

Sendo τ_g e τ_e os torques antes e depois da redução, respectivamente; J_m e J_w são as inércias do motor e da roda, respectivamente; B_m e B_w são os coeficientes de atrito viscoso do motor e da roda, respectivamente; K é a constante de torque do motor; j_i é a corrente no i -ésimo motor; N é o fator de redução e η é a eficiência do sistema de redução. Isolando τ_i em função dos demais termos, tem-se a Equação (12).

$$\tau_i = N \eta K j_i - \underbrace{(N^2 \eta J_m)}_{J_{eq}} \omega_i - \underbrace{(N^2 \eta B_m + B_w)}_{B_{eq}} \omega_i \quad (12)$$

Substituindo a Equação (12) na Equação (8), obtêm-se a Equação (13), sendo I_4 a matriz identidade de ordem 4.

$$\underbrace{(H_r + J_{eq} I_4)}_{H_j} \underbrace{\begin{bmatrix} \dot{\omega}_1 \\ \dot{\omega}_2 \\ \dot{\omega}_3 \\ \dot{\omega}_4 \end{bmatrix}}_{\dot{v}_w} + \underbrace{B_{eq} I_4}_{C_j} \underbrace{\begin{bmatrix} \omega_1 \\ \omega_2 \\ \omega_3 \\ \omega_4 \end{bmatrix}}_{v_w} = \underbrace{N \eta K}_{k_j} \underbrace{\begin{bmatrix} j_1 \\ j_2 \\ j_3 \\ j_4 \end{bmatrix}}_j \quad (13)$$

A Equação (13) trata a dinâmica em função da corrente j enviada para o motor, e é muito útil para o caso da implementação de uma malha de corrente. Pode-se ainda representar essa equação em função da tensão no motor, bastando para isso utilizar a Equação (14).

$$j_i = \frac{V_i - V_{backemf}}{R} = \frac{V_i - K \omega_i}{R} \quad (14)$$

Sendo V_i a tensão no i -ésimo motor, $V_{backemf}$ a força contra-eletromotriz induzida e R a resistência do motor. Substituindo a Equação (14) na Equação (13) obtêm-se a Equação (15).

$$\underbrace{(H_r + J_{eq} I_4)}_{H_v} \underbrace{\begin{bmatrix} \dot{\omega}_1 \\ \dot{\omega}_2 \\ \dot{\omega}_3 \\ \dot{\omega}_4 \end{bmatrix}}_{\dot{v}_w} + \underbrace{\left(B_{eq} + \frac{N \eta K^2}{R} \right) I_4}_{C_v} \underbrace{\begin{bmatrix} \omega_1 \\ \omega_2 \\ \omega_3 \\ \omega_4 \end{bmatrix}}_{v_w} = \underbrace{\frac{N \eta K}{R}}_{k_v} \underbrace{\begin{bmatrix} V_1 \\ V_2 \\ V_3 \\ V_4 \end{bmatrix}}_V \quad (15)$$

Por fim, o sistema pode ainda ser representado na forma de espaço de estados, conforme Equação (16).

$$\dot{v}_w = \underbrace{-H_v^{-1} C_v}_{A} v_w + \underbrace{k H_v^{-1}}_B \underbrace{V}_u = A v_w + B u \quad (16)$$

2.3 Modelo de rastreamento de trajetória

Agora falta resolver o problema de rastreamento de trajetória. Primeiramente, define-se as variáveis de controle que serão usadas no nosso modelo, a saber $u = [v, v_n, \omega]^T$. Além disso, a dinâmica de movimento do robô não linear segue a Equação (17) retirada diretamente da análise da Figura 2.

$$\dot{q}(t) = \begin{bmatrix} \dot{x}(t) \\ \dot{y}(t) \\ \dot{\theta}(t) \end{bmatrix} = \begin{bmatrix} \cos\theta & -\sin\theta & 0 \\ \sin\theta & \cos\theta & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} v \\ v_n \\ \omega \end{bmatrix} \quad (17)$$

Sendo $q = [x, y, \theta]^T$ o vetor de estados do robô. O sistema de visão diretamente mede o estado do robô q .

Os motores das rodas são motores DC, os quais possuem um limite de velocidade devido ao limite de voltagem da bateria. Além disso, o campo possui dimensões fixas, e portanto o caminho pelo qual o robô pode caminhar durante o jogo é limitado, no entanto essa restrição só realmente precisa ser aplicada durante uma partida. Dessa forma, as Inequações (18), (19) e (20).

$$-\omega_{MAX} \leq \omega_i \leq \omega_{MAX} \quad (18)$$

$$-X_{MAX} \leq x_i \leq X_{MAX} \quad (19)$$

$$-Y_{MAX} \leq y_i \leq Y_{MAX} \quad (20)$$

Apesar de certas diferenças de notação e, principalmente, as modificações nas equações para o robô omnidirecional, o equacionamento a seguir segue o mostrado em (Klančar and Škrjanc, 2007) e (Maximo, 2012). Considere um robô virtual que segue perfeitamente a trajetória de referência. O robô real terá um erro estacionário $e(t) = [e_1(t), e_2(t), e_3(t)]^T$ como mostrado na Figura 4. Isso pode ser escrito no sistema de coordenadas reais do robô como na Equação (21).




Figura 4. Erro entre o robô seguindo perfeitamente a trajetória e o robô real.

$$e = \begin{bmatrix} \cos\theta & \sin\theta & 0 \\ -\sin\theta & \cos\theta & 0 \\ 0 & 0 & 1 \end{bmatrix} (q_r - q) \quad (21)$$

Derivando a equação (21) e substituindo nela a Equação (17), chega-se a Equação (22).

$$\dot{e} = \begin{bmatrix} v \\ v_n \\ \omega \end{bmatrix} + \begin{bmatrix} -1 & 0 & e_2 \\ 0 & -1 & e_1 \\ 0 & 0 & -1 \end{bmatrix} u \quad (22)$$

Pode-se pensar na variável de controle u como composta por componentes, sendo um *feedforward* u_F e um *feedback* u_B . Levando em conta o erro de orientação, tem-se a Equação (23).

$$u_F = \begin{bmatrix} v \cos(e_3) \\ v_n \cos(e_3) \\ \omega \end{bmatrix} \quad (23)$$

Substituindo $u = u_F + u_B$ na Equação (22), obtêm-se a Equação (24).

$$\dot{e} = \begin{bmatrix} v(1 - \cos(e_3)) + \omega e_2 \\ v_n(1 - \cos(e_3)) + \omega e_1 \\ \omega \end{bmatrix} + \begin{bmatrix} -1 & 0 & e_2 \\ 0 & -1 & e_1 \\ 0 & 0 & -1 \end{bmatrix} u \quad (24)$$

Tal sistema de equações é não linear, mas nota-se que o ponto de referencia da trajetória do sistema, ou seja, $e = 0_{3 \times 1}$ e $u_B = 0_{3 \times 1}$, é um ponto de equilíbrio, já que $\dot{e}(e = 0_{3 \times 1}, u_B = 0_{3 \times 1}) = 0_{3 \times 1}$. Com isso, pode-se linearizar o sistema em torno da referência da trajetória, o que resulta na Equação (25).

$$\dot{\bar{e}} = \underbrace{\begin{bmatrix} 0 & \omega & 0 \\ -\omega & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}}_A \bar{e} + \underbrace{\begin{bmatrix} -1 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & -1 \end{bmatrix}}_B \bar{u}_B \quad (25)$$

2.4 Modelo em tempo contínuo no espaço de estados

Sendo \bar{e} e \bar{u}_B respectivamente o erro linearizado e a variável de controle linearizada. O sistema pode ser então expresso na forma de espaço de estados, conforme Equação (26). y é a saída do sistema e C é a matriz que transforma a variável \bar{e} na saída do sistema, e trata-se da identidade de ordem 3.

$$\begin{aligned} \dot{\bar{e}} &= A\bar{e} + B\bar{u}_B \\ y &= C\bar{e} \end{aligned} \quad (26)$$

Vale ainda ressaltar que a matriz A varia no tempo, por ser função da velocidade angular do robô, e por isso deve ser recalculada em cada *timestep*. A notação de barra sobre as variáveis linearizadas será deixada implícita nas equações a seguir por questões de simplicidade, no entanto, a seguir sempre será usado o sistema já linearizado.

3. CONTROLE PREDITIVO (MPC)

A técnica de controle preditivo resolve um problema de otimização considerando o comportamento futuro do sistema e culmina em uma sequência ótima de ações de controle (Camacho and Bordons, 2007). O sistema de controle do presente trabalho possui as seguintes características: modelo que varia linearmente no tempo, do tipo MIMO, implementação em tempo discreto, função de custo quadrática, uso de horizonte retrocedente e com tratamento de restrições.

3.1 Discretização no tempo

O sistema foi discretizado utilizando a Equação (27), conhecida como discretização exata ou *Zero-Order-Hold* (ZOH) (Camacho and Bordons, 2007). Dessa forma, obteve-se as matrizes A_d e B_d do espaço de estados para tempo discreto, conforme Equação (28), com um período de amostragem de $T = 0.005$ s. A e B são as matrizes do espaço de estados em tempo contínuo na Equação (26).

$$\begin{cases} A_d = -e^{-AT} \\ B_d = \int_0^T -e^{-A\xi} B d\xi \end{cases} \quad (27)$$

$$\begin{aligned} e(k+1) &= A_d(k)e(k) + B_d(k)u_b(k) \\ y(k) &= Ce(k) \end{aligned} \quad (28)$$

3.2 Função de custo

A função de custo J utilizada foi do tipo quadrada com horizonte de controle e de predição finitos (Camacho and Bordons, 2007; Klančar and Škrjanc, 2007; Maximo, 2012) como pode ser visto na Equação (29).

$$\begin{aligned} J(\hat{e}(k+i|k), \Delta\hat{u}_B(k+i-1|k)) &= \\ &\sum_{i=1}^N (\hat{e}(k+i|k) - e_r)^T Q (\hat{e}(k+i|k) - e_r) \\ &+ \sum_{i=1}^M \Delta\hat{u}_B(k+i-1|k)^T R \Delta\hat{u}_B(k+i-1|k) \end{aligned} \quad (29)$$

Sendo N o horizonte de predição e M o horizonte de controle, sendo $M \geq N$. $\Delta u_B(k)$ trata-se dos incrementos de controle aplicados e possui a seguinte forma: $\Delta u_B(k) = u_B(k) - u_B(k-1)$. Os acentos circunflexos por sobre as variáveis indica valores preditos, ou seja, são as ações futuras do sistema. Q e R são as matrizes peso do erro de estado e do esforço de controle, respectivamente. $Q \in R^3 \times R^3$ e $R \in R^3 \times R^3$ são matrizes diagonais, com $Q > 0$ e $R > 0$. Por fim, e_r é a referência para o controle, no caso, tratando-se do erro entre a trajetória atual e a trajetória planejada pelo robô. Utiliza-se sempre $e_r = 0_{3 \times 1}$.

3.3 Predição

Para o processo de predição, definem-se os vetores apresentados na Equação (30).

$$\begin{aligned} \hat{y} &= \begin{bmatrix} \hat{y}(k+1|k) \\ \hat{y}(k+2|k) \\ \vdots \\ \hat{y}(k+N|k) \end{bmatrix}_{3 \cdot N \times 1} ; \quad \hat{u} = \begin{bmatrix} \hat{u}_B(k|k) \\ \hat{u}_B(k+1|k) \\ \vdots \\ \hat{u}_B(k+M-1|k) \end{bmatrix}_{3 \cdot M \times 1} ; \\ ref &= \begin{bmatrix} e_r \\ e_r \\ \vdots \\ e_r \end{bmatrix}_{3 \cdot N \times 1} ; \quad \Delta\hat{u} = \begin{bmatrix} \Delta\hat{u}_B(k|k) \\ \Delta\hat{u}_B(k+1|k) \\ \vdots \\ \Delta\hat{u}_B(k+M-1|k) \end{bmatrix}_{3 \cdot M \times 1} \end{aligned} \quad (30)$$

Com isso, a função custo pode agora ser representada como na Equação (31).

$$J(\hat{y}, \Delta\hat{u}) = (\hat{y} - ref)^T Q (\hat{y} - ref) + \Delta\hat{u}^T R \Delta\hat{u} \quad (31)$$

Tomando a solução da Equação (31), que será resolvida em 3.5, chega-se na Equação (32) (Camacho and Bordons, 2007) que trata-se da equação de predição em termos de \hat{u} .

$$\hat{y} = H\hat{u} + f_u \quad (32)$$

Com as matrizes H e f_u apresentadas na Equação (33).

$$\begin{aligned} H &= \begin{bmatrix} CB_d & 0 & \cdots & 0 \\ CA_d B_d & CB_d & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ CA_d^{N-1} B & CA_d^{N-2} B & \cdots & CB_d \end{bmatrix}_{3 \cdot N \times 3 \cdot N} \\ f_u &= \Phi_u e(k), \quad \Phi_u = \begin{bmatrix} CA_d \\ CA_d^2 \\ \vdots \\ CA_d^N \end{bmatrix}_{3 \cdot N \times 3} \end{aligned} \quad (33)$$

No entanto, para ficar na forma mais clássica do MPC, deseja-se exprimir a equação de predição em termos do incremento de controle $\Delta\hat{u}$, e, para isso, utiliza-se a estratégia do estado aumentado, criando-se o estado aumentado $\xi(k)$ conforme a Equação (34). Assim, a equação em espaço de estados se torna a Equação (35), que fica em termos de $\Delta\hat{u}$. Ficam também definidas as matrizes do espaço de estados aumentado \tilde{A}, \tilde{B} e \tilde{C}

$$\xi(k) = \begin{bmatrix} e(k) \\ u_B(k-1) \end{bmatrix} \quad (34)$$

$$\begin{aligned} \xi(k+1) &= \underbrace{\begin{bmatrix} A_d & B_d \\ 0_{3 \times 3} & I_3 \end{bmatrix}}_{\tilde{A}} \xi(k) + \underbrace{\begin{bmatrix} B_3 \\ I_3 \end{bmatrix}}_{\tilde{B}} \Delta u_B(k) \\ y(k) &= \underbrace{[C \ 0_{3 \times 3}]}_{\tilde{C}} \xi(k) \end{aligned} \quad (35)$$

A equação de predição fica sendo então a Equação (36).

$$\hat{y} = G\Delta\hat{u} + f \quad (36)$$

Com as matrizes G e f apresentadas na Equação (37).

$$\begin{aligned} G &= \begin{bmatrix} \tilde{C}\tilde{B} & 0 & \cdots & 0 \\ \tilde{C}\tilde{A}\tilde{B} & \tilde{C}\tilde{B} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \tilde{C}\tilde{A}^{N-1}\tilde{B} & \tilde{C}\tilde{A}^{N-2}\tilde{B} & \cdots & \tilde{C}\tilde{B} \end{bmatrix}_{3 \cdot N \times 3 \cdot N} \\ f &= \Phi\xi(k), \quad \Phi = \begin{bmatrix} \tilde{C}\tilde{A} \\ \tilde{C}\tilde{A}^2 \\ \vdots \\ \tilde{C}\tilde{A}^N \end{bmatrix}_{3 \cdot N \times 3} \end{aligned} \quad (37)$$

3.4 Tratamento de restrições

Da Inequação (18), vem a Inequação (38).

$$\begin{bmatrix} -\omega_{max} \\ -\omega_{max} \\ -\omega_{max} \\ -\omega_{max} \end{bmatrix} \leq \underbrace{\begin{bmatrix} \omega_1 \\ \omega_2 \\ \omega_3 \\ \omega_4 \end{bmatrix}}_{\omega_w} \leq \begin{bmatrix} \omega_{max} \\ \omega_{max} \\ \omega_{max} \\ \omega_{max} \end{bmatrix} \quad (38)$$

No entanto, da condição de não deslizamento, $\omega_w = \frac{v_w}{r}$. Combinando esse fato, a Inequação (38), a Equação (3) e o fato de que $u = [v, v_n, \omega]^T$, ter-se-á a Equação (39), que impõe as restrições na variável de controle.

$$\underbrace{\frac{1}{r}M^+ \begin{bmatrix} -\omega_{max} \\ -\omega_{max} \\ -\omega_{max} \\ -\omega_{max} \end{bmatrix}}_{u_{min}} \leq u_F + u_B \leq \underbrace{\frac{1}{r}M^+ \begin{bmatrix} \omega_{max} \\ \omega_{max} \\ \omega_{max} \\ \omega_{max} \end{bmatrix}}_{u_{max}} \Rightarrow u_{B_{min}} = u_{min} - u_F \leq u_B \leq u_{B_{max}} = u_{max} - u_F \quad (39)$$

Para deixar em função do vetor de incrementos de controle, basta deixar na forma da Equação (40).

$$\begin{bmatrix} T_M^{I_3} \\ -T_M^{I_3} \end{bmatrix} \Delta \hat{u} \leq \begin{bmatrix} u_{B_{max}} - u(k-1) \\ u(k-1) - u_{B_{min}} \end{bmatrix}_M, \quad T_M^{I_3} = \begin{bmatrix} I_3 & 0_{3 \times 3} & \cdots & 0_{3 \times 3} \\ I_3 & I_3 & \cdots & 0_{3 \times 3} \\ \vdots & \vdots & \ddots & \vdots \\ I_3 & I_3 & \cdots & I_3 \end{bmatrix} \quad (40)$$

Agora, das Inequações (19) e (20), vem a Inequação (41). Como não foram impostas restrições a rotação, convencionou-se dizer que tais restrições são infinito.

$$\underbrace{\begin{bmatrix} -X_{max} \\ -Y_{max} \\ -\infty \end{bmatrix}}_{e_{min}} \leq \underbrace{\begin{bmatrix} e_1 \\ e_2 \\ e_3 \end{bmatrix}}_e \leq \underbrace{\begin{bmatrix} X_{max} \\ Y_{max} \\ \infty \end{bmatrix}}_{e_{max}} \quad (41)$$

Colocando em termos do vetor de saídas \hat{y} através das Equações (26) e (30), chega-se a Inequação (42).

$$[y_{min}]_N \leq \hat{y} \leq [y_{max}]_N \quad (42)$$

Combinando a Inequação (42) com a Equação (36), pode-se exprimir as restrições em termos do vetor de incrementos de controle, segundo a Inequação (43).

$$\begin{bmatrix} G \\ -G \end{bmatrix} \Delta \hat{u} \leq \begin{bmatrix} [[y_{max}]_N - f]_M \\ [f - [y_{min}]_N]_M \end{bmatrix} \quad (43)$$

Combinando a Inequação (40) com a Inequação (43), chega-se a Inequação (44).

$$\underbrace{\begin{bmatrix} T_M^{I_3} \\ -T_M^{I_3} \\ G \\ -G \end{bmatrix}}_S \Delta \hat{u} \leq \underbrace{\begin{bmatrix} [u_{B_{max}} - u(k-1)]_M \\ [u(k-1) - u_{B_{min}}]_M \\ [[y_{max}]_N - f]_M \\ [f - [y_{min}]_N]_M \end{bmatrix}}_b \quad (44)$$

Chegando-se por fim em uma equação da forma $S\Delta \hat{u} \leq b$, que descreve todas as restrições do sistema.

3.5 Calculando o controle ótimo

Após certa manipulação algébrica na Equação (31) pode-se chegar na Equação (45). Termos constantes foram removidos da equação por não influenciarem na otimização.

$$J(\Delta \hat{u}) = \frac{1}{2} \Delta \hat{u}^T H_{qp} \Delta \hat{u} + f_{qp}^T \Delta \hat{u}, \quad \text{sujeito a } S\Delta \hat{u} \leq b \quad (45)$$

Sendo os termos H_{qp} e f_{qp} definidos na Equação (46).

$$\begin{aligned} H_{qp} &= 2(G^T Q G + R) \\ f_{qp} &= 2(QG)^T (f - ref) \end{aligned} \quad (46)$$

O controle ótimo pode então ser dado pelo problema de otimização de minimizar a função custo dada na Equação (45). Tal problema de otimização é conhecido como Programação Quadrática. Apesar de a cada instante toda a sequencia de controle ser calculada, em um dado instante k , o comando de controle é dado efetivamente por $u_B(k) = u_B(k-1) + [I_3 \ 0_{3 \times 3(M-1)}] \Delta \hat{u}^*$.

4. SIMULAÇÕES

As simulações foram feitas com a utilização do *software* MATLAB/Simulink. Para resolver o problema de programação quadrática foi utilizada a função `quadprog` do MATLAB. As trajetórias de referência foram geradas utilizando curvas de Lissajous apenas para servir como exemplo, cujas equações paramétricas seguem as Equações (47) e (48).

$$X(t) = A_1 \sin(\omega_1 t + \delta) \quad (47)$$

$$Y(t) = A_2 \sin(\omega_2 t) \quad (48)$$

Sendo A_1 , A_2 , ω_1 e δ parâmetros.

Para todas as simulações foram usados os parâmetros da Tabela ?? que não correspondem com as restrições reais do robô, foram impostos apenas para testes e simulações.

Parâmetro	Valor
ω_{max}	3.5 rad/s
T	0.005 s
ω_1	1
ω_2	2
A_1	1
A_2	1.5
δ	$\pi/2$
M	20
N	15

Além disso, foi fixado $Q = \text{diag}(15, 20, 40)$ e $R = \text{diag}(0.05, 0.05, 0.05)$. Vale ressaltar que quanto maior a matriz Q , mais rapidamente a referência será atingida, no entanto, o ruído do sistema se amplifica, servindo a matriz R como um filtro que torna o sistema mais robusto a ruídos.

Para uma melhor comparação com a situação real, o movimento do robô foi simulado sobre um desenho de campo estilo *Small Size*.

4.1 Sem adição de perturbações e ruído

O resultado da simulação sem adição de perturbações e ruído pode ser verificado na Figura 5.




Figura 5. Gráfico do movimento do robô sobre a trajetória planejada. Em preto a trajetória de referência e em vermelho a trajetória realmente cumprida.

4.2 Resposta a perturbações e ruído

Para a simulação com ruído e perturbações foi adicionado um ruído de posição de covariância 0.001 e média zero e um deslocamento em degrau da posição do robô após 1 segundo de simulação. O resultado da simulação com adição de perturbações e ruído pode ser verificado na Figura 6.

Os resultados obtidos foram satisfatórios e mostraram que o robô é capaz de seguir a trajetória e se recuperar de perturbações externas. Levantamentos de requisitos para que os pesos das matrizes possam ser definidos e um modelo do ruído da câmera serão incluídos em trabalhos futuros.

4.3 Análise do respeito a restrições

É possível ainda observar a resposta do controlador a restrições impostas. A restrição de velocidade angular da roda imposta foi intencionalmente restritiva para que esse efeito pudesse ser verificado. Um gráfico comparativo entre a velocidade angular desenvolvida e a máxima permitida na simulação com ruído incluso pode ser verificado na Figura 7. Verifica-se que as restrições foram bem respeitadas pelo controlador.




Figura 6. Gráfico do movimento do robô sobre a trajetória planejada. Em preto a trajetória de referência e em vermelho a trajetória realmente cumprida. Destaque para a resposta ao ruído e ao deslocamento após 1 segundo de simulação.

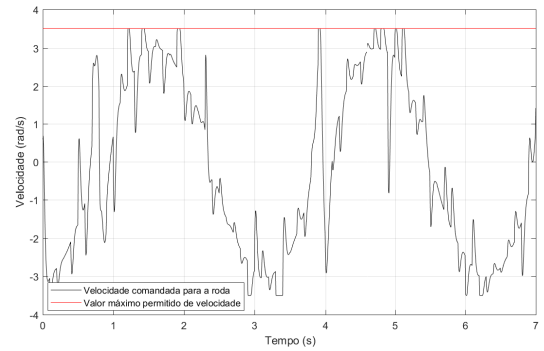


Figura 7. Gráfico comparando o valor máximo permitido para a velocidade angular da roda (em vermelho) e a velocidade comandada pelo controlador (em preto). Nota-se claramente que as restrições foram respeitadas.

5. CONCLUSÃO

Apesar dos desafios que o problema de seguir trajetórias na robótica possa representar, o controlador preditivo se mostrou capaz de, com maestria, contornar esse problema sem se desatentar as restrições que são impostas, conseguindo seguir a trajetória, corrigir perturbações e criar um filtro que barra o ruído sem descumprir as limitações do sistema.

Para trabalhos futuros, deseja-se fazer um levantamento de requisitos através de simulações e observações do robô, além de um levantamento de um modelo de ruído de posição do robô para que os pesos das matrizes Q e R possam ser melhor projetados. Além disso, deseja-se observar quantitativamente o efeito dos horizontes M e N no sistema. Por fim, deseja-se também implementar o controlador no robô e o observar na prática. Seria também interessante estabelecer as diferenças quantitativas entre o preditivo e outros controladores como o PID voltado para o *Small Size*.

6. AGRADECIMENTOS

O autor gostaria de agradecer a equipe ITAndroids, em especial ao prof. Dr Marcos Máximo, por todo o apoio e suporte no trabalho, e aos patrocinadores da equipe e ao ITA por tornarem tais pesquisas possíveis.

REFERÊNCIAS

- Camacho, E.F. and Bordons, C.C. (2007). *Model Predictive Control*. Springer, London.
- Klančar, G. and Skrjanc, I. (2007). Tracking-error model-based predictive control for mobile robots in real time. *Robotics and Autonomous Systems*, 55(6), 460–469. doi: 10.1016/J.ROBOT.2007.01.002.
- Maximo, M.R.O.A. (2012). Model Predictive Controller for Trajectory Tracking by Differential Drive Robot With Actuation Constraints. 6.
- Maximo, M.R.O.A. (2018). ITAndroids Small Size Relatório do Modelamento da Dinâmica do Robô. Technical report.
- RoboCup (2019). Rules of the RoboCup Small Size League 2019. 1–33.
- Siegwart, R., Nourbakhsh, I.R., and Scaramuzza, D. (2011). *Introduction to autonomous mobile robots*.