

## Aula 9

14 Maio 2019

# Resumo da aula passada

- Tratamento de restrições - Implementação do caso SISO
- Extensão ao caso MIMO

# Tópicos da aula de hoje

- Estabilidade em malha fechada

# Ponto de equilíbrio

Considere um sistema com dinâmica a tempo discreto descrita por um modelo da forma

$$x(k+1) = f(x(k))$$

sendo  $f : \mathbb{R}^n \rightarrow \mathbb{R}^n$  uma função possivelmente não linear.

Um ponto  $\bar{x} \in \mathbb{R}^n$  é dito ser um ponto de equilíbrio do sistema se

$$f(\bar{x}) = \bar{x}$$

Nas definições a seguir, consideraremos que a origem é um ponto de equilíbrio ( $\bar{x} = 0$ ).

O ponto de equilíbrio  $\bar{x} = 0$  é dito ser **estável** se, para qualquer  $\varepsilon > 0$ , existir  $\delta(\varepsilon) > 0$  tal que

$$\|x(0)\| < \delta(\varepsilon) \Rightarrow \|x(k)\| < \varepsilon, \quad \forall k \geq 0$$

Caso contrário, o ponto de equilíbrio é dito ser **instável**.

# Estabilidade assintótica

O ponto de equilíbrio  $\bar{x} = 0$  é dito ser **assintoticamente estável** se for estável e se existir  $\delta_1 > 0$  tal que

$$\|x(0)\| < \delta_1 \Rightarrow \|x(k)\| \xrightarrow{k \rightarrow \infty} 0$$

Nesse caso, o conjunto  $B_{\delta_1}$  definido por

$$B_{\delta_1} = \{x \in \mathbb{R}^n : \|x\| < \delta_1\}$$

é dito ser um **domínio** (“região”, “bacia”) **de atração** para a origem.

Se o domínio de atração for todo o  $\mathbb{R}^n$ , diz-se que o ponto de equilíbrio é **globalmente assintoticamente estável**.

# Sistemas discretos lineares e invariantes no tempo

Considere um sistema com dinâmica a tempo discreto descrita por um modelo da forma

$$x(k+1) = Ax(k)$$

com  $A \in \mathbb{R}^{n \times n}$ .

Pode-se mostrar que a origem é um ponto de equilíbrio assintoticamente estável se e somente se (s.s.s) todos os **autovalores** da matriz  $A$  tiverem **módulo menor do que um**.

Nesse caso, a origem é o único ponto de equilíbrio do sistema e a estabilidade assintótica é global.

Por essa razão, costuma-se também dizer que o **sistema** é (assintoticamente) estável.

## Exemplo (Maciejowski, p. 168)

Seja um sistema com dinâmica descrita por

$$x_1(k+1) = u(k)$$

$$x_2(k+1) = x_1(k)$$

(Atraso de dois períodos de amostragem)

Suponha que o controle a ser aplicado no instante  $k$  seja obtido por meio da solução do seguinte problema de otimização:

$$\begin{aligned} \min_{\hat{x}_1(k+1|k), \hat{x}_2(k+1|k),} \quad & J = \hat{x}_1^2(k+1|k) + 4\hat{x}_1(k+1|k)\hat{x}_2(k+1|k) + 6\hat{x}_2^2(k+1|k) \\ & \hat{u}(k|k) \in \mathbb{R} \end{aligned}$$

s.a.

$$\hat{x}_1(k+1|k) = \hat{u}(k|k)$$

$$\hat{x}_2(k+1|k) = x_1(k)$$



**Obs:** O custo também poderia ser escrito como

$$J = \hat{x}^T(k+1|k)Q\hat{x}(k+1|k)$$

sendo

$$x(k) = \begin{bmatrix} x_1(k) \\ x_2(k) \end{bmatrix}, \quad Q = \begin{bmatrix} 1 & 2 \\ 2 & 6 \end{bmatrix}$$

Vale notar que  $Q > 0$  (autovalores em 0,3 e 6,7).

$$\min J = \hat{x}_1^2(k+1|k) + 4\hat{x}_1(k+1|k)\hat{x}_2(k+1|k) + 6\hat{x}_2^2(k+1|k)$$

s.a.

$$\hat{x}_1(k+1|k) = \hat{u}(k|k)$$

$$\hat{x}_2(k+1|k) = x_1(k)$$

Substituindo as expressões de  $\hat{x}_1(k+1|k)$ ,  $\hat{x}_2(k+1|k)$  na função de custo, tem-se

$$J = \hat{u}^2(k|k) + 4\hat{u}(k|k)x_1(k) + 6x_1^2(k)$$

$$\frac{dJ}{d\hat{u}(k|k)} = 2\hat{u}(k|k) + 4x_1(k)$$

Impondo que esta derivada seja igual a zero, chega-se a

$$\hat{u}^*(k|k) = -2x_1(k)$$

$$\begin{aligned}x_1(k+1) &= u(k) \\x_2(k+1) &= x_1(k)\end{aligned}$$

Fazendo  $u(k) = \hat{u}^*(k|k) = -2x_1(k)$ , obtêm-se as seguintes equações de estado:

$$\begin{aligned}x_1(k+1) &= -2x_1(k) \\x_2(k+1) &= x_1(k)\end{aligned}$$

ou seja

$$x(k+1) = \underbrace{\begin{bmatrix} -2 & 0 \\ 1 & 0 \end{bmatrix}}_{A_{mf}} x(k)$$

Como  $A_{mf}$  possui um autovalor em  $-2$  (fora do círculo unitário), conclui-se que o sistema é instável em malha fechada.

Neste caso, a instabilidade pode ser evitada introduzindo uma penalização do esforço de controle na função de custo:

$$J = \hat{x}_1^2(k+1|k) + 4\hat{x}_1(k+1|k)\hat{x}_2(k+1|k) + 6\hat{x}_2^2(k+1|k) + \rho\hat{u}^2(k|k)$$

com  $\rho > 0$ .

Substituindo as expressões de  $\hat{x}_1(k+1|k)$ ,  $\hat{x}_2(k+1|k)$  na função de custo, obtém-se

$$J = (1 + \rho)\hat{u}^2(k|k) + 4\hat{u}(k|k)x_1(k) + 6x_1^2(k)$$

$$\frac{dJ}{d\hat{u}(k|k)} = 2(1 + \rho)\hat{u}(k|k) + 4x_1(k)$$

$$\hat{u}^*(k|k) = -\frac{2}{1 + \rho}x_1(k)$$

$$x_1(k+1) = u(k), \quad x_2(k+1) = x_1(k)$$

Fazendo  $u(k) = \hat{u}^*(k|k) = -\left(\frac{2}{1+\rho}\right)x_1(k)$ , chega-se a

$$x(k+1) = \underbrace{\begin{bmatrix} -\frac{2}{1+\rho} & 0 \\ 1 & 0 \end{bmatrix}}_{A_{mf}} x(k)$$

Agora os autovalores da matriz  $A_{mf}$  são 0 e  $-\frac{2}{1+\rho}$ .

Logo, a dinâmica de malha fechada será assintoticamente estável s.s.s.  $\rho > 1$ .

Seria desejável formular o problema de otimização de modo que a estabilidade assintótica fosse garantida  $\forall \rho > 0$ .

Pode-se argumentar que um aspecto inconveniente, neste exemplo, é o horizonte de predição excessivamente curto ( $N = 1$ ). De fato, tomando  $N = 2$  e  $M = 1$ , tem-se

$$\begin{aligned} J = & [\hat{x}_1^2(k+1|k) + 4\hat{x}_1(k+1|k)\hat{x}_2(k+1|k) + 6\hat{x}_2^2(k+1|k)] + \\ & [\hat{x}_1^2(k+2|k) + 4\hat{x}_1(k+2|k)\hat{x}_2(k+2|k) + 6\hat{x}_2^2(k+2|k)] + \\ & \rho \hat{u}^2(k|k) \end{aligned}$$

s.a.

$$\begin{aligned} \hat{x}_1(k+1|k) &= \hat{u}(k|k) \\ \hat{x}_2(k+1|k) &= x_1(k) \\ \hat{x}_1(k+2|k) &= \hat{u}(k+1|k) = \hat{u}(k|k) \\ \hat{x}_2(k+2|k) &= \hat{x}_1(k+1|k) = \hat{u}(k|k) \end{aligned}$$

considerando, como de costume, que  $\hat{u}$  permanece constante após o final do horizonte de controle.

Pode-se argumentar que um aspecto inconveniente, neste exemplo, é o horizonte de predição excessivamente curto ( $N = 1$ ). De fato, tomando  $N = 2$  e  $M = 1$ , tem-se

$$J = [\hat{x}_1^2(k+1|k) + 4\hat{x}_1(k+1|k)\hat{x}_2(k+1|k) + 6\hat{x}_2^2(k+1|k)] + \\ [\hat{x}_1^2(k+2|k) + 4\hat{x}_1(k+2|k)\hat{x}_2(k+2|k) + 6\hat{x}_2^2(k+2|k)] + \\ \rho \hat{u}^2(k|k)$$

s.a.

$$\hat{x}_1(k+1|k) = \hat{u}(k|k)$$

$$\hat{x}_2(k+1|k) = x_1(k)$$

$$\hat{x}_1(k+2|k) = \hat{u}(k+1|k) = \hat{u}(k|k)$$

$$\hat{x}_2(k+2|k) = \hat{x}_1(k+1|k) = \hat{u}(k|k)$$

considerando, como de costume, que  $\hat{u}$  permanece constante após o final do horizonte de controle.

Substituindo as expressões para os valores preditos do estado na função de custo, obtém-se

$$\begin{aligned} J &= \hat{u}^2(k|k) + 4\hat{u}(k|k)x_1(k) + 6x_1^2(k) + \\ &\quad \hat{u}^2(k|k) + 4\hat{u}^2(k|k) + 6\hat{u}^2(k|k) + \rho\hat{u}^2(k|k) \\ &= (12 + \rho)\hat{u}^2(k|k) + 4\hat{u}(k|k)x_1(k) + 6x_1^2(k) \\ \frac{dJ}{d\hat{u}(k|k)} &= 2(12 + \rho)\hat{u}(k|k) + 4x_1(k) \\ \hat{u}^*(k|k) &= - \left( \frac{2}{12 + \rho} \right) x_1(k) \end{aligned}$$

Com isso, tem-se

$$A_{mf} = \begin{bmatrix} -\frac{2}{12 + \rho} & 0 \\ 1 & 0 \end{bmatrix}$$

o que permite concluir que a dinâmica de malha fechada é assintoticamente estável  $\forall \rho > 0$ .



## Importância do horizonte de predição empregado

Como se vê, o horizonte de predição tem um papel importante na estabilidade da malha de controle.

Um resultado bem conhecido é o do Regulador Linear Quadrático (LQR) de **horizonte infinito**. Nesse caso, o problema consiste em minimizar uma função de custo da forma

$$J = \sum_{i=0}^{\infty} [\hat{x}^T(k+i|k)Q\hat{x}(k+i|k) + \hat{u}^T(k+i|k)R\hat{u}(k+i|k)] ,$$

$$Q = Q^T > 0, R = R^T > 0$$

s.a.

$$\hat{x}(k+i+1|k) = A\hat{x}(k+i|k) + B\hat{u}(k+i|k), \quad i \geq 0$$

$$\hat{x}(k|k) = x(k)$$

Se o par  $(A, B)$  for controlável, pode-se mostrar que a solução ótima é dada por

$$\hat{u}^*(k+i|k) = -K\hat{x}^*(k+i|k)$$

com ganho  $K$  calculado como

$$K = (R + B^T P B)^{-1} B^T P A$$

sendo  $P > 0$  obtida como solução da seguinte Equação Algébrica de Riccati:

$$P = A^T P A - A^T P B (R + B^T P B)^{-1} B^T P A + Q$$


Empregando a lei de controle  $u(k) = \hat{u}^*(k|k) = -Kx(k)$ , a dinâmica de malha fechada é garantidamente estável.

De fato, se  $(A, B)$  for controlável, garantidamente existem matrizes  $K_{est}$  tais que os autovalores de  $(A - BK_{est})$  estejam no interior do círculo unitário, tornando a malha estável.

Evidentemente, a solução ótima do LQR de horizonte infinito não pode resultar em uma malha instável.

**O que se perde ao usar um horizonte de predição finito ?**

# Princípio da Otimalidade\*




Se a trajetória  $\overline{ABC}$  é ótima partindo de  $A$ , então a trajetória  $\overline{BC}$  é ótima partindo de  $B$ .

---


\*Bellman, R. E. Dynamic Programming. Princeton University Press, 1957.

Com efeito, suponha por absurdo que a trajetória ótima partindo de  $B$  fosse  $\overline{BD}$ , como indicado abaixo:




Nesse caso, a trajetória ótima partindo de  $A$  seria  $\overline{ABD}$ , e não  $\overline{ABC}$ .

# Horizonte Infinito



# Horizonte Finito



# **Uso de Horizonte de Predição Infinito com Horizonte de Controle Finito**



- Dinâmica da planta:

$$x(k+1) = Ax(k) + Bu(k)$$

com  $x(k) \in \mathbb{R}^n$ ,  $u(k) \in \mathbb{R}^p$ .

- Custo a ser minimizado no instante  $k$ :

$$J(k) = \sum_{i=0}^{\infty} \|\hat{x}(k+i|k)\|_Q^2 + \sum_{i=0}^{N-1} \|\hat{u}(k+i|k)\|_R^2$$

sendo

$$\|x\|_Q^2 = x^T Q x, \quad \|u\|_R^2 = u^T R u$$

com  $Q = Q^T > 0$  e  $R = R^T > 0$ .

- Equações de predição:

$$\hat{x}(k|k) = x(k)$$

$$\hat{x}(k+i+1|k) = A\hat{x}(k+i|k) + B\hat{u}(k+i|k), \quad i = 0, 1, \dots, N-1$$

$$\hat{x}(k+i+1|k) = A\hat{x}(k+i|k), \quad i \geq N$$

- Restrições sobre os controles e estados:

$$\hat{u}(k+i|k) \in \mathcal{U}, \quad i = 0, 1, \dots, N-1$$

$$\hat{x}(k+i|k) \in \mathcal{X}, \quad i \geq 0$$

sendo  $\mathcal{U} \subset \mathbb{R}^p$  e  $\mathcal{X} \subset \mathbb{R}^n$  conjuntos contendo a origem em seu interior.

- Lei de controle com horizonte retrocedente:

$$u(k) = \hat{u}^*(k|k)$$

## Observações:

- Limitantes sobre a excursão dos estados e controles são um caso particular das restrições aqui consideradas.
- Restrições sobre o incremento de controle  $\Delta u$  podem ser incorporadas ao problema empregando um modelo com estado aumentado

$$\xi(k) = \begin{bmatrix} x(k) \\ u(k-1) \end{bmatrix}$$

**Se o problema de otimização for factível no instante  $k$ , a factibilidade será mantida no instante  $k + 1$ .**

Com efeito, seja

$$\hat{u}^*(k|k), \hat{u}^*(k+1|k), \dots, \hat{u}^*(k+N-1|k)$$

a sequência ótima de controle obtida como solução do problema de otimização no instante  $k$ . Seja ainda

$$\hat{x}^*(k|k), \hat{x}^*(k+1|k), \dots$$

a respectiva sequência de estados preditos, com

$$\hat{x}^*(k|k) = x(k)$$

Aplicando-se à planta o controle

$$u(k) = \hat{u}^*(k|k)$$

segue que

$$x(k+1) = Ax(k) + Bu(k) = A\hat{x}^*(k|k) + B\hat{u}^*(k|k) = \hat{x}^*(k+1|k)$$

No instante  $(k + 1)$ , deve-se encontrar uma sequência de controle

$$\hat{u}(k + 1|k + 1), \hat{u}(k + 2|k + 1), \dots, \hat{u}(k + N|k + 1)$$

satisfazendo a restrição

$$\hat{u}(k + i + 1|k + 1) \in \mathcal{U}, \quad i = 0, 1, \dots, N - 1$$

e tal que a sequência de estados preditos por meio de

$$\hat{x}(k + 1|k + 1) = x(k + 1)$$

$$\hat{x}(k + i + 2|k + 1) = A\hat{x}(k + i + 1|k + 1) + B\hat{u}(k + i + 1|k + 1), \quad i = 0, 1, \dots, N - 1$$

$$\hat{x}(k + i + 2|k + 1) = A\hat{x}(k + i + 1|k + 1), \quad i \geq N$$

satisfaça a restrição

$$\hat{x}(k + i + 1|k + 1) \in \mathcal{X}, \quad i \geq 0$$

Vamos mostrar que essas restrições são satisfeitas empregando-se a seguinte **solução candidata**:

$$\hat{u}^c(k+1|k+1) = \hat{u}^*(k+1|k)$$

$$\hat{u}^c(k+2|k+1) = \hat{u}^*(k+2|k)$$

$$\vdots$$

$$\hat{u}^c(k+N-1|k+1) = \hat{u}^*(k+N-1|k)$$

$$\hat{u}^c(k+N|k+1) = 0$$

$$\begin{aligned}
\hat{u}^c(k+1|k+1) &= \hat{u}^*(k+1|k) \\
\hat{u}^c(k+2|k+1) &= \hat{u}^*(k+2|k) \\
&\vdots \\
\hat{u}^c(k+N-1|k+1) &= \hat{u}^*(k+N-1|k) \\
\hat{u}^c(k+N|k+1) &= 0
\end{aligned}$$

Essa solução trivialmente satisfaz as restrições de controle, uma vez que

$$\begin{aligned}
\hat{u}^*(k+1|k) &\in \mathcal{U} \\
\hat{u}^*(k+2|k) &\in \mathcal{U} \\
&\vdots \\
\hat{u}^*(k+N-1|k) &\in \mathcal{U}
\end{aligned}$$

e  $0 \in \mathcal{U}$ .



A sequência de estados preditos associada à solução candidata é dada por

$$\hat{x}^c(k+1|k+1) = x(k+1)$$

$$\hat{x}^c(k+2|k+1) = A\hat{x}^c(k+1|k+1) + B\hat{u}^c(k+1|k+1)$$

$$\vdots$$

$$\hat{x}^c(k+N|k+1) = A\hat{x}^c(k+N-1|k+1) + B\hat{u}^c(k+N-1|k+1)$$

$$\hat{x}^c(k+N+1|k+1) = A\hat{x}^c(k+N|k+1) + B\hat{u}^c(k+N|k+1)$$

$$\hat{x}^c(k+N+2|k+1) = A\hat{x}^c(k+N+1|k+1)$$

$$\vdots$$

Lembrando ainda que  $x(k+1) = \hat{x}^*(k+1|k)$ , tem-se

$$\hat{x}^c(k+1|k+1) = \hat{x}^*(k+1|k)$$

$$\hat{x}^c(k+2|k+1) = A\hat{x}^c(k+1|k+1) + B\hat{u}^*(k+1|k)$$

$$\vdots$$

$$\hat{x}^c(k+N|k+1) = A\hat{x}^c(k+N-1|k+1) + B\hat{u}^*(k+N-1|k)$$

$$\hat{x}^c(k+N+1|k+1) = A\hat{x}^c(k+N|k+1) + 0$$

$$\hat{x}^c(k+N+2|k+1) = A\hat{x}^c(k+N+1|k+1)$$

$$\vdots$$

Portanto, chega-se à sequência

$$\hat{x}^c(k+1|k+1) = \hat{x}^*(k+1|k)$$

$$\hat{x}^c(k+2|k+1) = \hat{x}^*(k+2|k)$$

$$\vdots$$

$$\hat{x}^c(k+N|k+1) = \hat{x}^*(k+N|k)$$

$$\hat{x}^c(k+N+1|k+1) = A\hat{x}^*(k+1|k) = \hat{x}^*(k+N+1|k)$$

$$\hat{x}^c(k+N+2|k+1) = A\hat{x}^*(k+N+1|k) = \hat{x}^*(k+N+2|k)$$

$$\vdots$$

que, como assumido inicialmente, satisfaz as restrições de estado.

## Convergência do estado para a origem

Se o problema de otimização for inicialmente factível, o estado  $x(k)$  convergirá para a origem quando  $k \rightarrow \infty$ .

Com efeito, seja

$$J^*(k) = \sum_{i=0}^{\infty} \|\hat{x}^*(k+i|k)\|_Q^2 + \sum_{i=0}^{N-1} \|\hat{u}^*(k+i|k)\|_R^2$$

o valor mínimo do custo resultante da solução do problema de otimização no instante  $k$  (sujeito às restrições de estado e controle). Seja ainda

$$J^*(k+1) = \min_{\substack{\hat{u}(k+i+1|k+1) \\ i=0,1,\dots,N-1}} \sum_{i=0}^{\infty} \|\hat{x}(k+i+1|k+1)\|_Q^2 + \sum_{i=0}^{N-1} \|\hat{u}(k+i+1|k+1)\|_R^2$$

o valor mínimo do custo para o problema de otimização no instante  $k+1$ .

Como visto anteriormente, as sequências de estado e controle dadas por

$$\begin{array}{l|l} \hat{u}^c(k+1|k+1) = \hat{u}^*(k+1|k) & \hat{x}^c(k+1|k+1) = \hat{x}^*(k+1|k) \\ \hat{u}^c(k+2|k+1) = \hat{u}^*(k+2|k) & \hat{x}^c(k+2|k+1) = \hat{x}^*(k+2|k) \\ \vdots & \vdots \\ \hat{u}^c(k+N-1|k+1) = \hat{u}^*(k+N-1|k) & \\ \hat{u}^c(k+N|k+1) = 0 & \end{array}$$

formam uma solução factível (não necessariamente ótima) para o problema de otimização no instante  $k+1$ .

Logo:

$$\begin{aligned} J^*(k+1) &\leq \sum_{i=0}^{\infty} \|\hat{x}^c(k+i+1|k+1)\|_Q^2 + \sum_{i=0}^{N-1} \|\hat{u}^c(k+i+1|k+1)\|_R^2 \\ &= \sum_{i=0}^{\infty} \|\hat{x}^*(k+i+1|k)\|_Q^2 + \sum_{i=0}^{N-2} \|\hat{u}^*(k+i+1|k)\|_R^2 \\ &= \left[ \sum_{i=0}^{\infty} \|\hat{x}^*(k+i|k)\|_Q^2 + \sum_{i=0}^{N-1} \|\hat{u}^*(k+i|k)\|_R^2 \right] - \|\hat{x}^*(k|k)\|_Q^2 - \|\hat{u}^*(k|k)\|_R^2 \\ &= J^*(k) - \|\hat{x}^*(k|k)\|_Q^2 - \|\hat{u}^*(k|k)\|_R^2 = J^*(k) - \underbrace{\left( \|x(k)\|_Q^2 + \|u(k)\|_R^2 \right)}_{\geq 0} \end{aligned}$$

$$J^*(k+1) - J^*(k) \leq - \underbrace{\left( \|x(k)\|_Q^2 + \|u(k)\|_R^2 \right)}_{\geq 0}$$

Tem-se então que  $J^*(k+1) \leq J^*(k)$ . Como a sequência  $\{J^*(k), k = 0, 1, \dots\}$  é limitada inferiormente (por zero), conclui-se que a mesma é convergente<sup>§</sup>. Portanto:

$$J^*(k) - J^*(k+1) \xrightarrow{k \rightarrow \infty} 0$$

---

<sup>§</sup> Vide, por exemplo: ZORICH, V. A. **Mathematical Analysis I**. Berlin: Springer-Verlag, 2004 (páginas 87 e 88).

Por outro lado, sabe-se que

$$0 \leq \left( \|x(k)\|_Q^2 + \|u(k)\|_R^2 \right) \leq J^*(k) - J^*(k+1)$$

Lembrando que  $Q > 0$  e  $R > 0$ , conclui-se que

$$u(k) \xrightarrow{k \rightarrow \infty} 0$$

$$x(k) \xrightarrow{k \rightarrow \infty} 0$$



**Obs:** Esta linha de argumentação é apresentada por Kwon e Han (2005).

A demonstração de **estabilidade** da origem envolveria o uso da função-valor  $J^*(k)$  como uma candidata a função de Lyapunov.

Alternativamente, pode-se argumentar que haverá uma vizinhança da origem na qual as restrições estarão inativas e, portanto: (i) o problema de otimização será factível e (ii) a aplicação do controle com horizonte retrocedente resultará em uma lei de controle linear. Como todas as trajetórias iniciadas dentro dessa vizinhança convergirão para a origem, com uma dinâmica linear e invariante no tempo, conclui-se que a origem é assintoticamente estável.

---

Referência: KWON, W.H.; HAN, S. **Receding Horizon control**, London: Springer-Verlag, 2005.

# **Implementação da lei de controle preditivo com horizonte de predição infinito e horizonte de controle finito**

- Custo a ser minimizado no instante  $k$ :

$$J(k) = \sum_{i=0}^{\infty} \|\hat{x}(k+i|k)\|_Q^2 + \sum_{i=0}^{N-1} \|\hat{u}(k+i|k)\|_R^2$$

com  $Q = Q^T > 0$  e  $R = R^T > 0$ .

- Modelo de predição:

$$\hat{x}(k|k) = x(k)$$

$$\hat{x}(k+i+1|k) = A\hat{x}(k+i|k) + B\hat{u}(k+i|k), \quad 0 \leq i \leq N-1$$

$$\hat{x}(k+i+1|k) = A\hat{x}(k+i|k), \quad i \geq N$$

Vamos inicialmente considerar o caso em que a planta é assintoticamente estável em malha aberta, isto é, a matriz  $A$  tem todos os autovalores no interior do “círculo unitário” (círculo centrado na origem do plano complexo, com raio unitário).

- Restrições sobre os controles e estados:

$$\hat{u}(k+i|k) \in \mathcal{U}, \quad i = 0, 1, \dots, N-1$$

$$\hat{x}(k+i|k) \in \mathcal{X}, \quad i \geq 0$$

sendo  $\mathcal{U}$  e  $\mathcal{X}$  definidos por meio de desigualdades lineares da forma

$$\mathcal{U} = \{u \in \mathbb{R}^p : S_u u \leq b_u\}$$

$$\mathcal{X} = \{x \in \mathbb{R}^n : S_x x \leq b_x\}$$

Inicialmente, vamos reescrever o custo da seguinte forma:

$$\begin{aligned} J(k) &= \sum_{i=0}^{\infty} \|\hat{x}(k+i|k)\|_Q^2 + \sum_{i=0}^{N-1} \|\hat{u}(k+i|k)\|_R^2 \\ &= \underbrace{\sum_{i=N}^{\infty} \|\hat{x}(k+i|k)\|_Q^2}_{J_f(k)} + \sum_{i=0}^{N-1} \|\hat{x}(k+i|k)\|_Q^2 + \|\hat{u}(k+i|k)\|_R^2 \end{aligned}$$

Lembrando que

$$\hat{x}(k+i+1|k) = A\hat{x}(k+i|k), \quad i \geq N$$

pode-se escrever

$$\hat{x}(k+i|k) = A^{(i-N)}\hat{x}(k+N|k), \quad i \geq N$$

Portanto:

$$J_f(k) = \sum_{i=N}^{\infty} \|\hat{x}(k+i|k)\|_Q^2 = \sum_{i=N}^{\infty} \|A^{(i-N)}\hat{x}(k+N|k)\|_Q^2$$

ou ainda, fazendo  $j = i - N$ :

$$J_f(k) = \sum_{j=0}^{\infty} \|A^j \hat{x}(k+N|k)\|_Q^2 = \hat{x}^T(k+N|k) \underbrace{\left[ \sum_{j=0}^{\infty} (A^j)^T Q A^j \right]}_{P_f} \hat{x}(k+N|k)$$

$$J_f(k) = \hat{x}^T(k + N|k)P_f\hat{x}(k + N|k)$$

$$P_f = \sum_{j=0}^{\infty} (A^j)^T Q A^j$$

A convergência dessa somatória é garantida pela hipótese de que os autovalores de  $A$  estão no interior do círculo unitário.

Como calcular  $P_f$  ?

$$P_f = \sum_{j=0}^{\infty} (A^j)^T Q A^j \Rightarrow A^T P_f A = \sum_{j=1}^{\infty} (A^j)^T Q A^j = P_f - Q$$

Portanto,  $P_f$  pode ser obtida como solução da seguinte **Equação de Lyapunov**:

$$A^T P_f A - P_f + Q = 0$$

Matlab: Função DLYAP

**Obs:** Se  $Q > 0$ , pode-se mostrar que  $P_f > 0$ . Com efeito, dado  $x \neq 0$ , tem-se

$$x^T P_f x = x^T \left( \sum_{j=0}^{\infty} (A^j)^T Q A^j \right) x = \underbrace{x^T Q x}_{>0} + \sum_{j=1}^{\infty} \underbrace{x^T (A^j)^T Q A^j x}_{\geq 0} > 0$$



O custo pode ser reescrito como

$$J(k) = \|\hat{x}(k+N|k)\|_{P_f}^2 + \sum_{i=0}^{N-1} \|\hat{x}(k+i|k)\|_Q^2 + \|\hat{u}(k+i|k)\|_R^2$$

ou ainda

$$J(k) = \|x(k)\|_Q^2 + \hat{\mathbf{x}}^T \begin{bmatrix} Q & 0 & \cdots & 0 \\ 0 & Q & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & P_f \end{bmatrix} \hat{\mathbf{x}} + \hat{\mathbf{u}}^T \begin{bmatrix} R & 0 & \cdots & 0 \\ 0 & R & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & R \end{bmatrix} \hat{\mathbf{u}}$$

sendo

$$\hat{\mathbf{x}} = \begin{bmatrix} \hat{x}(k+1|k) \\ \hat{x}(k+2|k) \\ \vdots \\ \hat{x}(k+N|k) \end{bmatrix}, \quad \hat{\mathbf{u}} = \begin{bmatrix} \hat{u}(k|k) \\ \hat{u}(k+1|k) \\ \vdots \\ \hat{u}(k+N-1|k) \end{bmatrix}$$

As restrições sobre o controle:

$$S_u \hat{u}(k+i|k) \leq b_u, \quad i = 0, 1, \dots, N-1$$

podem ser expressas como desigualdades lineares envolvendo  $\hat{\mathbf{u}}$ .

Resta tratar as restrições sobre o estado:

$$S_x \hat{x}(k+i|k) \leq b_x, \quad i \geq 0$$


→ **Infinidade de restrições !**

Uma forma de contornar essa dificuldade consiste na imposição de restrições terminais.


# **Uso de horizonte de predição finito e restrições terminais**

Uma forma de garantir a estabilidade empregando horizonte de predição finito consiste em impor que a origem seja alcançada ao final do horizonte de predição (restrição terminal).

No instante  $k$ , impõe-se  $\hat{x}(k + N|k) = 0$ :



No instante  $k + 1$ , impõe-se  $\hat{x}(k + N|k + 1) = 0$ :



Se o problema de otimização for inicialmente factível, a origem será atingida em  $N$  passos.

Esta abordagem equivale a usar um horizonte de predição que vai sendo reduzido a cada passo.

Como alternativa, pode-se colocar a restrição sempre  $N$  passos à frente do instante atual, isto é, impor

$$\hat{x}(k + N|k) = 0$$

$$\hat{x}(k + N + 1|k + 1) = 0$$

e assim sucessivamente.

- Custo a ser minimizado no instante  $k$ :

$$J(k) = \sum_{i=0}^{N-1} \|\hat{x}(k+i|k)\|_Q^2 + \|\hat{u}(k+i|k)\|_R^2$$

- Restrições de controle e estado:

$$S_u \hat{u}(k+i|k) \leq b_u$$

$$S_x \hat{x}(k+i|k) \leq b_x$$

para  $i = 0, 1, \dots, N-1$ .

- Restrição terminal:

$$\hat{x}(k+N|k) = 0$$

Empregando argumentação similar à utilizada para o horizonte de predição infinito, pode-se mostrar que o problema de otimização tem factibilidade recursiva e que o estado  $x(k)$  convergirá para a origem quando  $k \rightarrow \infty$ .



# MPC para regulação com garantia de estabilidade nominal

## Informação requerida sobre a planta:

- Matrizes  $A \in \mathbb{R}^{n \times n}$ ,  $B \in \mathbb{R}^{n \times p}$  do modelo no espaço de estados
- Limitantes sobre a excursão dos estados:  $x_{min}, x_{max} \in \mathbb{R}^n$
- Limitantes sobre a excursão dos controles:  $u_{min}, u_{max} \in \mathbb{R}^p$

## Parâmetros de projeto:

- Matrizes de peso  $Q \in \mathbb{R}^{n \times n}$  e  $R \in \mathbb{R}^{p \times p}$
- Horizonte de predição  $N$

## Inicialização:

- Fazer

$$H = \begin{bmatrix} B & 0 & \cdots & 0 \\ AB & B & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ A^{N-1}B & A^{N-2}B & \cdots & B \end{bmatrix}, \quad \Phi_u = \begin{bmatrix} A \\ A^2 \\ \vdots \\ A^N \end{bmatrix}$$

$$\mathbf{Q} = \begin{bmatrix} Q & 0 & \cdots & 0 \\ 0 & Q & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & Q \end{bmatrix}_{qN \times qN}, \quad \mathbf{R} = \begin{bmatrix} R & 0 & \cdots & 0 \\ 0 & R & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & R \end{bmatrix}_{pN \times pN}$$

- Calcular  $H_n = \mathbf{Q}H$
- Fazer  $H_{qp} = 2(H^T \mathbf{Q}H + \mathbf{R})$

- Fazer  $A_{qp} = \begin{bmatrix} I_{pN} \\ -I_{pN} \\ H \\ -H \end{bmatrix}$
- Fazer  $A_{eq} = \begin{bmatrix} 0_{n \times (n-1)N} & I_n \end{bmatrix} H$  (últimas  $n$  linhas de  $H$ ).
- Fazer  $k = 0$

## Rotina principal:

- 1 Ler  $x(k)$  (estado da planta)
- 2 Calcular  $\mathbf{f}_u = \Phi_u x(k)$  e  $f_{qp} = 2H_n^T \mathbf{f}_u$
- 3 Fazer

$$b_{qp} = \begin{bmatrix} [u_{max}]_N \\ -[u_{min}]_N \\ [x_{max}]_N - \mathbf{f}_u \\ \mathbf{f}_u - [x_{min}]_N \end{bmatrix}$$

- 4 Fazer  $b_{eq} = -[0_{n \times (n-1)N} \ I_n] \mathbf{f}_u$  (últimas  $n$  linhas de  $\mathbf{f}_u$ )
- 5 Resolver o problema de otimização

$$\hat{\mathbf{u}}^* = \arg \min_{\hat{\mathbf{u}} \in \mathbb{R}^{pM}} \frac{1}{2} \hat{\mathbf{u}}^T H_{qp} \hat{\mathbf{u}} + f_{qp}^T \hat{\mathbf{u}}$$

s.a.

$$A_{qp} \hat{\mathbf{u}} \leq b_{qp}, \quad A_{eq} \hat{\mathbf{u}} = b_{eq}$$

- ⑥ Atualizar o controle aplicado à planta:  $u(k) = \hat{u}^*(k|k)$
- ⑦ Fazer  $k = k + 1$
- ⑧ Aguardar o próximo instante de amostragem e retornar ao passo 1.

## Observação: Restrição de igualdade

A restrição  $A_{eq}\hat{\mathbf{u}} = b_{eq}$  pode ser imposta por meio de uma parametrização do vetor  $\hat{\mathbf{u}}$  na forma

$$\hat{\mathbf{u}} = Z\theta + \hat{\mathbf{u}}_0$$

sendo  $Z$  uma matriz cujas colunas formem uma base para o espaço nulo de  $A_{eq}$  e  $\hat{\mathbf{u}}_0$  uma solução particular da equação  $A_{eq}\hat{\mathbf{u}} = b_{eq}$ .

Supondo que  $A_{eq}$  tenha posto completo de linhas, uma solução particular é dada por

$$\hat{\mathbf{u}}_0 = A_{eq}^T (A_{eq} A_{eq}^T)^{-1} b_{eq}$$

Com isso, o problema de otimização pode ser reformulado em termos do vetor  $\theta$ .

No Matlab, a matriz  $Z$  pode ser obtida fazendo  $Z = \text{null}(A_{eq})$

Detalhes a respeito desse procedimento podem ser consultados em:

GOULD, N. I. M.; HRIBAR, M. E.; NOCEDAL, J. On the solution of equality constrained quadratic programming problems arising in optimization. **SIAM Journal on Scientific Computing**, v. 23, n. 4, p. 1376-1395, 2001.

# Implementação em Matlab

- `matrizes_regulador_estabilidade.m`: Monta as matrizes  $\Phi_u, H_n, H_{qp}, A_{qp}, A_{eq}$ .
- `mpc_regulador_estabilidade.m`: S-function que implementa o controlador

Exemplo:

- `exemplo_regulador_estabilidade.m`: Definição das matrizes do modelo da planta (integrador duplo) e dos pesos do MPC.
- `regulador_estabilidade.mdl`: Diagrama de simulação.



# Implementação em Matlab: Exemplo

Parâmetros do controlador:

- $N = 10$
- $u_{max} = -u_{min} = 0,2$
- $x_{max} = -x_{min} = [2 \ 2]^T$

Condições iniciais da planta:

- $x(0) = [1 \ 0]^T$

O que acontece se  $x(0) = [1 \ 0,65]^T$  ?

# Tópicos da próxima aula

- Caracterização do domínio de atração da origem ao se empregar a lei de controle preditivo.
- Alternativa para ampliação do domínio de atração: Uso de conjunto terminal.